MOONLIT TAVERN

月下酒馆

交付与测试报告

版本 0.1.0 · 构建 #14 · 提交 35aa1c4

仓库 github.com/wwuwubo/moonlit-tavern

2026 年 10 月 29 日

本文档由@呜呜鼬创建，未经许可不得外传。

目录

1 结论 3

1.1 验收问题一览 3

1.2 关键数据 3

2 交付物 4

2.1 构建产物属于哪一种 4

3 技术调研 6

3.1 推理方案对比 6

3.2 设备与系统限制 6

3.3 版本兼容性 7

4 模型选择 8

4.1 候选比较 8

4.2 内存：理论估算与实测 9

5 软件架构 10

5.1 架构要求的落实 10

6 关键设计 11

6.1 提示词拼接顺序 11

6.2 世界书激活规则 11

6.3 长期记忆 12

6.4 多角色群聊 12

6.5 KV 缓存复用与回退 12

6.6 云端模式与隐私 12

7 里程碑完成情况 13

8 测试结果 15

8.1 单元测试 15

8.2 iOS 构建与 IPA 检查 15

8.3 引擎测试（真实模型） 16

8.4 模拟器端到端测试 16

8.5 没有覆盖的测试 18

9 验收问题与证据 19

10 真机测试清单 21

11 已知问题 22

12 后续开发路线 23

13 参考资料 24

1　结论

月下酒馆的源码、自动构建流程、未签名 IPA 和自动化测试已经全部完成。最新版本是构建 #14，源码提交 35aa1c4。

本地推理使用 llama.cpp 官方发布的 iOS 框架（b11960，Metal 加速）。在云端 macOS 上，同一份推理代码用真实 GGUF 模型跑通了单人对话、群聊、重新生成、停止、摘要和 8192 上下文；在 iPad 模拟器上，真实 App 完成了「启动 → 发消息 → 本地模型回复 → 退出重开 → 记录还在 → 接着聊」的完整流程。

尚未完成的是真机这一环：签名安装、M4 上的速度与内存表现，都要在你的 iPad 上完成。第 9 章列出每个验收问题的证据，第 10 章是一份照着做即可的真机测试清单。

1.1　验收问题一览

#	问题	状态
1	SwiftUI 工程是否真实存在	已完成并验证
2	是否通过真实的 iOS 编译	已完成并验证
3	是否产生了 IPA 或其他可供签名的构建产物	已完成并验证
4	是否可以导入角色卡	已完成并验证
5	聊天记录能否在重启后保留	已完成并验证（模拟器）
6	是否真正调用本地模型	已完成并验证
7	断网后能否生成 AI 回复	已实现但未验证
8	是否存在任何强制云端依赖	已完成并验证（不存在）
9	是否完成 8K 上下文测试	已完成并验证（macOS）；真机受环境限制
10	是否完成真实 iPad 设备测试	受环境限制

1.2　关键数据

- 单元测试 71 项全部通过（Linux Swift 6.0.3、macOS Swift 6.4）。
- iOS 真机构建：Xcode 27.1 + iOS 27.1 SDK、Xcode 26.6 + iOS 26.5 SDK 均成功，0 条编译警告。
- IPA：约 4.9 MB，arm64，内嵌 llama.framework，主程序调用 48 个 llama.cpp 接口，未签名。
- 引擎测试（macOS 虚拟机，真实模型）：Qwen3-0.6B 在 8192 上下文、Qwen3.5-0.8B 在 4096 上下文均通过 22 项检查；Qwen3.5-4B 完成加载与首轮生成。
- 模拟器端到端：首轮回复 9.5 秒，重启后继续对话 9.2 秒，测试通过。

2　交付物

交付物	文件或位置	说明
完整 Xcode 工程 ZIP	MoonlitTavern-XcodeProject.zip	源码、XcodeGen 工程描述、已生成的 .xcodeproj、脚本和测试。llama.xcframework 体积较大，不放进压缩包，运行 scripts/fetch-llama.sh 自动下载并校验
GitHub Actions Workflow	.github/workflows/	build.yml 测试、构建、发布；engine-test.yml 真实模型引擎测试；simulator-test.yml 模拟器端到端测试
IPA	MoonlitTavern-unsigned.ipa .sha256	真机 Release 构建，未签名。发布在 Releases 的 build-14
README	README.md	功能、目录结构、构建方法
模型下载及导入指南	docs/MODELS.md 《安装与使用指南》第 5 章	推荐模型、内存估算、三种导入方式
全能签安装指南	《月下酒馆 安装与使用指南》 docs/INSTALL.md	证书与描述文件要求、签名步骤、常见安装错误
功能测试报告	本报告 docs/TEST_REPORT.md	测试方法、结果和证据
构建日志	build-logs.zip、core-tests.log 仓库 ci-logs/* 分支 docs/evidence/	编译输出、IPA 结构检查、单元测试、引擎测试与模拟器测试日志
已知问题清单	本报告第 11 章 docs/KNOWN_ISSUES.md	
后续开发路线	本报告第 12 章 docs/ROADMAP.md	

仓库地址：https://github.com/wwuwubo/moonlit-tavern（私有）。构建记录在仓库的 Actions 页面，本版本对应 Build #14（运行编号 40788450491）。

2.1　构建产物属于哪一种

类型	本项目	说明
未签名 IPA	提供	Payload/MoonlitTavern.app 打包而成，里面没有证书和描述文件。iPadOS 不能直接安装，需要签名工具配合证书重签
已签名 IPA	不提供	签名需要你的证书（.p12）和描述文件。这两样属于敏感凭据，签名在你自己的全能签里完成
Xcode 工程	提供	有 Mac 时可直接打开编译、签名、安装

类型	本项目	说明
模拟器构建产物	只在测试中使用	模拟器版 .app 只能在 Mac 的模拟器里运行，装不到 iPad 上，所以不发布

> **说明**　未签名 IPA 能否通过全能签装上，取决于你的证书类型、描述文件是否登记了这台 iPad，以及证书是否被吊销。这一步没有经过实际测试。

3　技术调研

3.1　推理方案对比

方案	iPadOS 可用性与维护	GPU 加速	模型格式	Swift 集成	结论
llama.cpp + Metal	官方每个版本都发布 XCFramework，含 iOS 真机切片；更新频繁	Metal，着色器已内嵌	GGUF，量化档位齐全，社区模型最多	直接 import C 接口	采用
GGUF 的 Swift 封装库	大多是在 llama.cpp 外再包一层，版本跟进晚于上游	同 llama.cpp	GGUF	Swift Package	不采用：多一层依赖，KV 缓存回退、采样链等细节反而拿不到
Core ML	系统框架；iOS 18 起支持带状态的模型（KV 缓存）	GPU 或神经引擎	.mlpackage，需要用 coremltools 自己转换	原生	不采用：现成的中文对话模型很少，每换一个模型都要转换调试，分词和采样也要自己补
MLX（mlx-swift）	支持 iOS 真机；官方说明不支持模拟器	Metal	MLX（safetensors），mlx-community 有大量转换好的模型	Swift Package	备选：真机可行，但无法在云端模拟器上做端到端验证。本项目没有真机和 Mac，验证手段只剩云端，这一点是硬伤

选择 llama.cpp 的另一个原因是可验证性：官方 XCFramework 同时带有 macOS 切片，应用里的推理代码可以原样在云端 macOS 上跑真实模型测试。

3.2　设备与系统限制

- **内存上限**：8 GB 是整机统一内存。iPadOS 给单个 App 的上限 Apple 没有公开，会随机型和系统版本变化。App 运行时用 os_proc_available_memory() 读取系统允许的余量。公开资料里，有开发者在 8 GB 的 iPhone 16 Pro Max 上测得单进程约 6 GB（个人测量，仅作参考）。
- **increased-memory-limit 权限**：Apple 文档说明它只在部分机型生效，并要求 App 拿不到额外内存时也能正常工作。这个权限必须写进描述文件，全能签重签时只有你的描述文件带有该能力才有效。所以 App 默认不声明它，内存规划按默认上限设计。
- **后台**：iPadOS 不允许后台 App 提交 GPU 任务。App 进入后台前会停止推理，避免被系统终止。
- **沙盒**：模型放在 Documents/Models，「文件」App 里可见，可以直接把模型文件移进去；该目录排除在 iCloud 备份之外。
- **热限制**：长时间推理会让芯片降频。App 监听系统温度状态，偏高时在界面提示。

3.3 版本兼容性

项目	版本	结论
主力构建环境	Xcode 27.1（27A9275）· Swift 6.4 · iOS 27.1 SDK · macOS 27.0.1	构建通过
兼容构建环境	Xcode 26.6 · Swift 6.3.3 · iOS 26.5 SDK	构建通过
llama.cpp	b11960 官方 XCFramework，最低 iOS 16.4，动态框架	SHA-256 校验后使用
App 最低系统	iPadOS 17.0，仅 iPad	面向 iPadOS 27 编译
工程生成	XcodeGen（project.yml）	工程文件可重复生成，避免手改 pbxproj

4　模型选择

定位	模型	文件	大小	许可
首发主力	Qwen3.5-4B Q4_K_M	Qwen3.5-4B-Q4_K_M.gguf	2.74 GB	Apache-2.0
备用	Qwen3-4B-Instruct-2507 Q4_K_M	Qwen3-4B-Instruct-2507-Q4_K_M.gguf	2.50 GB	Apache-2.0
轻量	Qwen3.5-2B Q4_K_M	Qwen3.5-2B-Q4_K_M.gguf	1.28 GB	Apache-2.0

文件名与大小已在 Hugging Face 仓库的文件列表中逐一核对。App 内置这三个模型的下载入口（Hugging Face 官方地址与 hf-mirror 镜像）。

4.1　候选比较

维度	Qwen3.5-4B	Qwen3-4B-Instruct-2507	Qwen2.5-3B-Instruct
中文表达	强	强	较好
发布时间	2026 年 3 月	2025 年（2507 版）	2024 年 9 月
架构	混合：每 4 层 1 层完整注意力	标准 Transformer	标准 Transformer
8K 上下文 KV 缓存（Q8_0）	约 140 MB	约 640 MB	约 160 MB
思考模式	默认开启，App 关闭	无	无
对话模板	ChatML	ChatML	ChatML
许可	Apache-2.0	Apache-2.0	Qwen Research（非商用）
本项目实测	首轮输出符合人设，动作描写与对白格式正确（macOS 虚拟机）	未实测	未实测

Qwen3.5-4B 做主力，原因有三：中文好；KV 缓存小，8 GB 机型余量大；Apache-2.0 许可。它默认开启思考模式，App 在对话模板里预填空的思考段将其关闭，并在输出中过滤残留的思考标签。备用选 Qwen3-4B-Instruct-2507，标准架构在 llama.cpp 里最成熟，作为兼容性兜底。

7B–8B 模型的 Q4 权重约 4.5–5 GB，加上 KV 缓存和计算缓冲，很可能超过 8 GB 机型的单 App 上限。App 不阻止加载，但不推荐日常使用。

4.2　内存：理论估算与实测

理论估算公式：权重（约等于文件大小）+ KV 缓存 + 计算缓冲（约 260–400 MB）+ App 自身（约 180 MB）。App 加载前读取 GGUF 文件头完成这个计算；超过系统允许值时自动把上下文降到 6144、4096……并提示。

模型	理论估算（8K，Q8_0 KV）	macOS 虚拟机实测进程内存
Qwen3.5-4B Q4_K_M	约 3.5 GB	加载后 2917 MB，生成后 3057 MB（8192 上下文）
Qwen3-4B-Instruct-2507 Q4_K_M	约 3.7 GB	未测
Qwen3-0.6B Q8_0（测试用）	—	1168–1225 MB（8192 上下文）
Qwen3.5-0.8B Q4_K_M（测试用）	—	663–793 MB（4096 上下文）

> **注意**　实测数据来自 GitHub 云端 macOS 虚拟机（Apple M2 Pro 虚拟机，14 GB 内存，虚拟 GPU）。macOS 与 iPadOS 统计 Metal 缓冲区的方式不同，这些数字只说明量级，iPad 上的真实数值以 App 内「真机性能测试」为准。

5　软件架构

层	位置	职责
界面	MoonlitTavern/UI	SwiftUI 视图。左侧角色与存档，中间对话，右侧角色、世界书、记忆、参数、上下文五个面板
应用状态	MoonlitTavern/App	主线程上的状态与业务流程：发送、生成、重新生成、分支、摘要、模型加载、生命周期
推理	MoonlitTavern/Inference MoonlitTavern/Providers	InferenceEngine 协议；LlamaEngine（本地）与 OpenAICompatibleEngine（云端）两个实现；模型库与设备内存读数
核心逻辑	Packages/MoonlitCore	角色卡、世界书、提示词组装、记忆、群聊调度、流式文本、GGUF 解析。不依赖 UIKit，可在 Linux 上测试
持久化	MoonlitCore/Persistence	每个角色、存档、世界书、记忆一个 JSON 文件，原子写入；损坏文件跳过并提示
安全	MoonlitTavern/Security	钥匙串保存 API Key

5.1　架构要求的落实

要求	做法	位置
UI 与推理引擎解耦	视图只读写应用状态，不接触引擎	App/AppState+Generation.swift
本地与云端统一接口	两个引擎实现同一协议，输出同一种事件流：阶段、文本增量、统计、结束	MoonlitCore/Inference/InferenceEngine.swift
持久化与业务分离	TavernStore 只负责读写，业务规则在应用状态和核心库	MoonlitCore/Persistence/TavernStore.swift
角色卡独立测试	9 项单元测试，配真实格式的样例文件	Tests/MoonlitCoreTests/CharacterCardTests.swift
推理不阻塞 UI	llama.cpp 调用在独立串行队列；提示词组装在后台任务；界面按流式事件刷新	Inference/LlamaEngine.swift
可取消	停止按钮或 ⌘. 设置取消标记，每个 token 检查一次，已生成内容保留	同上
后台、内存警告、卸载	进入后台立即停止推理，可选同时卸载模型；收到内存警告时停止生成或卸载模型；模型管理页可手动卸载	App/AppState.swift
模型存放位置	Documents/Models，排除 iCloud 备份	Inference/ModelLibrary.swift
不打包模型权重	IPA 只有 约 4.9 MB，模型单独下载或导入	Releases
第三方许可	llama.cpp / ggml 为 MIT；推荐模型均为 Apache-2.0	THIRD_PARTY_LICENSES.md

6　关键设计

6.1　提示词拼接顺序

1. 系统提示词：角色自带的优先，否则用全局默认；支持 {{char}}、{{user}}、{{original}} 等宏。
2. 世界书中位置为「角色前」的条目。
3. 角色设定。当前发言角色排第一；群聊里其他角色省略背景和场景，只保留身份、性格、说话风格。
4. 世界书中位置为「角色后」的条目。
5. 用户身份（persona）。
6. 剧情状态（键值对，例如 章节：第二夜）。
7. 长期记忆。
8. 示例对话，只用剩余空间，空间不够时最先舍弃。
9. 聊天历史。按深度插入「按深度」的世界书条目、作者注释和角色卡里的 depth_prompt。
10. 历史后指令；群聊额外加一句「现在轮到某某发言，只写某某的台词和动作」。
11. 回复前缀：群聊时预填「某某：」。

预算分配：可用空间 = 上下文长度 − 回复长度。世界书最多占 30%，记忆最多占 20%（且不超过各自的设置值），其余给聊天历史，最后剩下的给示例对话。历史放不下时从最早的消息开始截断，截断点保持稳定，避免每轮都滑动。

6.2　世界书激活规则

1. 过滤：禁用、内容为空、角色过滤不匹配、未到延迟条数、处于冷却期的条目不参与。
2. 触发：常驻条目直接激活；处于粘滞期的条目保持激活；其余条目扫描最近 N 条消息（扫描深度）中的关键词。支持区分大小写、整词匹配（仅对英文等拉丁字母生效）和正则 /.../标志。
3. 次要关键词：按「任一命中 / 全部命中 / 一个都不命中 / 没有全部命中」四种逻辑判断。
4. 剧情状态条件：等于、不等于、存在、不存在、大于等于、小于等于。
5. 概率：按条目设定的百分比决定是否生效。
6. 递归：已激活条目的内容再扫描一遍，条目可以设置「不被递归激活」或「不触发递归」。
7. 互斥组：同一组只保留优先级最高的一条。
8. 预算：超出 token 预算时按 常驻 > 粘滞 > 优先级 > 插入顺序 保留。
9. 输出：按位置分组（角色前、角色后、按深度），组内按插入顺序排列。

冲突处理靠两条规则：内容互相矛盾的条目放进同一互斥组；预算不够时先舍弃不重要的。每轮实际激活了哪些条目、各占多少 token，右侧「世界书」面板都能看到。

6.3 长期记忆

- **触发**：旧消息被挤出上下文时自动总结，也可以在记忆面板点「立即整理旧消息」。
- **内容**：一段摘要，加上关键事件、人物关系变化和剧情状态更新。关系只保留最新的一条，剧情状态直接写回存档。
- **检索**：置顶条目 → 最近两条摘要 → 其余按关键词重合度（IDF 加权）、重要度、新近程度、是否涉及当前角色打分，在记忆预算内注入。
- **可控**：每条记忆都能查看、编辑、置顶、删除。
- **防护**：小模型偶尔会照抄格式里的占位词或示例句子，解析时会把这类内容过滤掉，并有单元测试覆盖。

6.4 多角色群聊

- **发言顺序**：自然（被点名者优先，否则轮到最久没说话的）、轮流、按健谈度加权随机、手动指定。
- **身份隔离**：当前发言者的完整设定排在最前；回合末尾明确提示轮到谁；预填发言者名字；其他角色和用户的名字都设为停止词，模型一旦开始替别人说话就立即截断。
- **共享上下文**：所有角色共用同一段聊天历史、世界书和剧情状态。

6.5 KV 缓存复用与回退

- 每次生成比较新旧提示词的公共前缀，只计算新增部分。实测第二轮 672 个 token 只计算了 23 个。
- 关闭思考模式时，历史里的助手消息也补上空思考段，保证模板前后渲染一致，缓存才能命中。
- Qwen3.5 这类混合架构的循环状态不能按位置删除。App 在每次读完提示词后保存一个状态快照，重新生成或停止后再发时恢复快照，实测只需重算 1 个 token。

6.6 云端模式与隐私

- 默认本地模式，云端需要手动切换并填写地址与密钥。
- 本地模式下，App 里会联网的代码只有两处：你主动点击的模型下载，以及云端引擎本身（本地模式不会调用）。
- API Key 保存在钥匙串（仅本机、首次解锁后可读），界面只显示掩码；错误信息不回显请求头，日志不记录密钥。

7　里程碑完成情况

里程碑	项目	状态	证据
M1 工程基础	SwiftUI 工程、基本界面	已完成并验证	模拟器截图；构建日志
	角色增删改	已完成并验证	模拟器截图（角色编辑）；代码 AppState.swift
	本地聊天记录	已完成并验证	PersistenceTests；模拟器重启测试
	数据导入导出（角色卡、世界书、整体备份）	已完成并验证	CharacterCardTests、WorldInfoFormatTests、PersistenceTests
	单元测试、第一次编译	已完成并验证	71 项通过；首次编译通过后每次提交自动构建
M2 本地推理	集成 llama.cpp、加载 GGUF	已完成并验证	引擎测试日志；IPA 符号检查
	本地流式推理、停止	已完成并验证	引擎测试「停止生成」；模拟器截图（生成中）
	模型管理：导入、加载、卸载、删除	已完成并验证	模拟器测试识别并加载模型；引擎测试卸载
	模型管理：App 内下载	已实现但未验证	代码 ModelLibrary.swift；自动化测试未覆盖
	上下文控制、内存估算、自动降上下文	已完成并验证	GGUFTests、HistoryWindowTests；8192 长上下文测试
	真实构建测试	已完成并验证	Build #14
	真机推理与性能	受环境限制	没有真机
M3 酒馆功能	角色卡兼容（V1/V2/V3、JSON/PNG）	已完成并验证	CharacterCardTests
	世界书	已完成并验证	LorebookEngineTests 13 项
	角色扮演提示词模板	已完成并验证	PromptBuilderTests、ChatTemplateTests
	记忆摘要	已完成并验证	MemoryTests；引擎测试「摘要」
	多角色对话	已完成并验证	引擎测试「群聊」；模拟器截图
	分支剧情（重新生成版本、从任意消息分出存档）	已完成并验证	ChatTreeTests；引擎测试「重新生成」
M4 体验优化	云端 API	已实现但未验证	OpenAICompatibleTests 只覆盖请求格式与流式解析，未连接真实服务

里程碑	项目	状态	证据
	模型切换、性能统计、错误提示	已完成并验证	模拟器截图显示首 token、速度、内存
	数据备份与恢复	已完成并验证	PersistenceTests
	UI 优化（横竖屏、深色主题）	已完成并验证	模拟器横屏与竖屏截图
M5 安装与验收	Release 构建、导出产物	已完成并验证	Releases build-14
	验证 IPA 结构	已完成并验证	verify-ipa.log
	全能签安装流程	文档已提供；安装受环境限制	《安装与使用指南》
	测试清单	已完成并验证	本报告第 10 章

8　测试结果

8.1　单元测试

测试组	数量	覆盖内容
角色卡	9	V1 / V2 / V3 / TavernAI 字段别名导入，PNG 读写无损，未知字段原样保留，错误输入，CRC32
世界书引擎	13	常驻、关键词、扫描深度、大小写与整词、正则、次要关键词逻辑、概率、递归、互斥组、预算、排序、粘滞与冷却、延迟与条件、角色过滤
世界书格式	4	SillyTavern 世界书导入导出往返、角色卡内嵌世界书、原生格式
提示词组装	14	拼接顺序与宏、群聊身份隔离、历史截断锚点、示例对话舍弃、深度注入、隐藏消息、ChatML / Gemma / Llama 3 / Mistral 模板、前缀稳定
对话与流式文本	9	分支树、编辑隐藏与分出存档、UTF-8 半个字符、跨片段停止词、思考段隐藏、回复清理、群聊调度、Markdown
记忆	8	关键词提取、检索优先级与预算、摘要解析与容错、占位词与示例回声过滤、关系合并
推理相关	9	GGUF 文件头解析（标准与混合架构）、内存估算、OpenAI 请求体、流式 SSE 解析、错误信息不泄露请求头
持久化	5	读写往返与备份、损坏文件跳过、旧版设置兼容、备份路径穿越防护、示例数据标记

合计 71 项，在 Linux（Swift 6.0.3）和 macOS（Swift 6.4）上均全部通过。日志：docs/evidence/core-tests-linux.log、Release 附件 core-tests.log。

8.2　iOS 构建与 IPA 检查

构建	环境	结果
Build #14 · iOS 构建	Xcode 27.1 · iOS 27.1 SDK · Release · iphoneos	成功，0 条编译警告
Build #14 · 兼容构建	Xcode 26.6 · Swift 6.3.3 · iOS 26.5 SDK · Release · iphoneos	成功，IPA 结构检查通过

IPA 结构检查（scripts/verify-ipa.sh）逐项通过：

- Payload/MoonlitTavern.app 与 Info.plist 存在；Bundle ID com.wuwuyou.moonlittavern，版本 0.1.0，最低系统 17.0，DTSDKName 为 iphoneos27.1，设备族仅 iPad。
- 平台为 iphoneos（真机），主程序为 arm64。
- 主程序链接 @rpath/llama.framework/llama，框架已嵌入 Frameworks/，含 Metal 后端。
- 主程序引用 48 个 llama.cpp 接口，包括模型加载、上下文创建、解码、采样、分词、KV 缓存操作和状态快照。
- 未签名，不含描述文件；Assets.car 存在。

8.3 引擎测试（真实模型）

测试程序 Tools/EngineHarness 直接编译 App 里的 LlamaEngine.swift 和核心库，链接同一版本 llama.cpp 的 macOS 切片，在 GitHub 的 macOS 虚拟机上加载真实 GGUF 模型，跑 22 项检查：单人对话两轮、KV 缓存复用、重新生成回退、停止生成、群聊点名与不串台、思考段与模板符号不泄漏、UTF-8 完整、摘要解析、长上下文、卸载。

模型	上下文	结果	说明
Qwen3-0.6B Q8_0	8192	22 / 22	长上下文：提示词 7686 token 完整读入并生成；第二轮只计算 23 token；重新生成只计算 1 token
Qwen3.5-0.8B Q4_K_M	4096	22 / 22	混合架构；状态快照生效，重新生成只计算 1 token；摘要产出 3 条事件、1 条关系
Qwen3.5-4B Q4_K_M	8192	首轮 5 项通过	加载 4.2 秒，首轮回复符合人设。虚拟 GPU 太慢，为节省构建时长手动停止

> **注意** 这台虚拟机的 GPU 是 Apple Paravirtual device，不支持 simdgroup 矩阵运算，速度远低于真机（Qwen3-0.6B 读取约 42 token/秒、生成约 6 token/秒）。这些速度只用来确认功能正确，不代表 iPad 的性能。

8.4 模拟器端到端测试

测试 MoonlitTavernUITests 在 iPad Pro 13 英寸（M5）模拟器上启动真实 App，加载真实模型 Qwen3.5-0.8B Q4_K_M，为缩短时长把上下文设为 2048、回复上限设为 48 token。运行编号 40788449971，结果 TEST SUCCEEDED。

步骤	结果
启动 App	加载示例数据，聊天界面出现，示例存档含开场白
设置 › 模型管理	识别到测试模型并选中
输入并发送「你好，艾琳。今晚还有空房吗？」	出现停止按钮，进入生成状态
等待回复	9.5 秒后收到回复（含首次加载模型）；首 token 1.98 秒，读取 252 token/秒，生成 27.3 token/秒，进程内存 747 MB
右侧五个面板、角色编辑、群聊存档、竖屏	全部正常显示并截图
退出 App 再启动	用户消息 1/1、助手消息 2/2，最后一条回复文本与重启前完全一致
发送「那就要朝钟楼的那间。」	9.2 秒后收到新回复（含重新加载模型）；首 token 2.52 秒，生成 50.2 token/秒



图 1　本地模型回复（截去屏幕键盘），底部显示首 token、读取与生成速度、上下文和内存

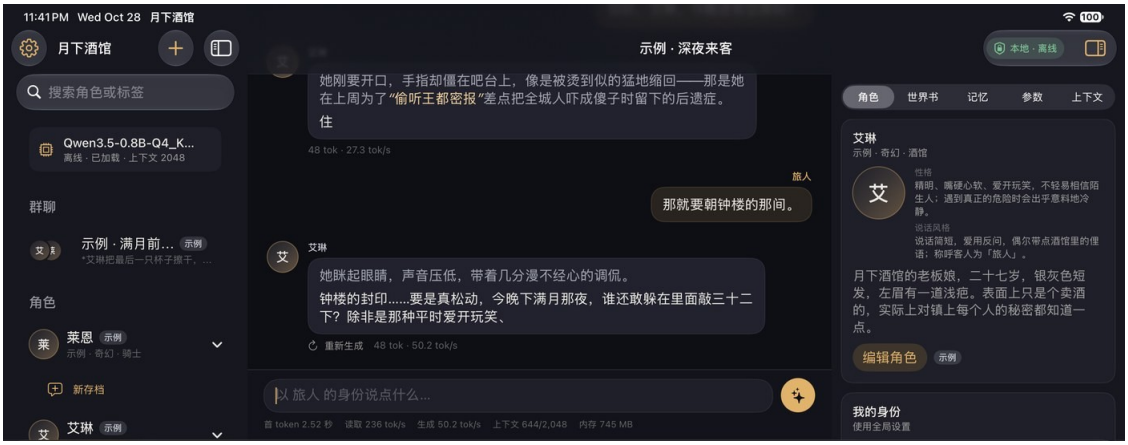


图 2　退出重开后，聊天记录完整保留，并继续生成了新回复（截去屏幕键盘）

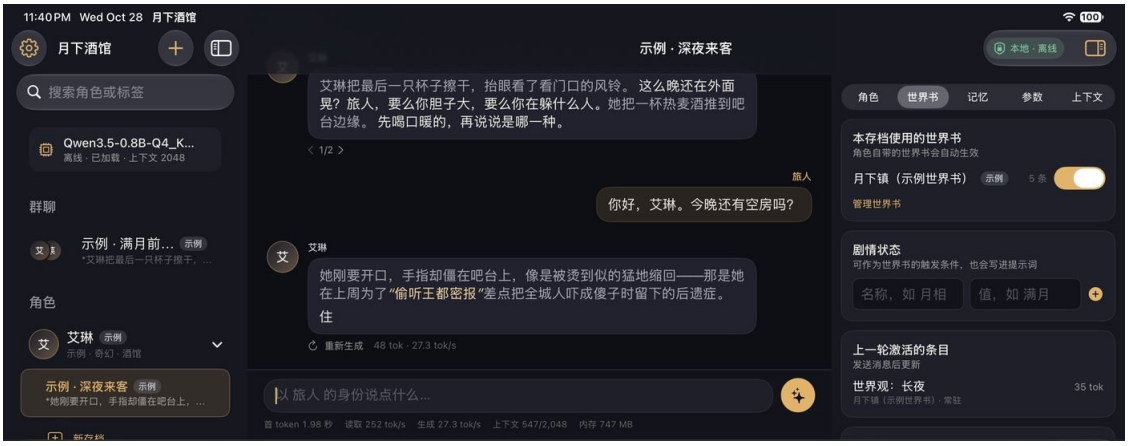


图 3　右侧「世界书」面板：本轮激活的条目与 token 用量（截去屏幕键盘）



图 4　群聊存档：选择发言角色与发言顺序

> **注意**　模拟器与真机的 GPU、内存管理差别很大，模拟器里 os_proc_available_memory() 返回 0。上面的速度和内存只说明流程跑通。

8.5　没有覆盖的测试

- 真机安装、真机推理、真机速度与内存（没有 iPad 真机）。
- 全能签签名安装（需要你的证书）。
- 断网条件下的推理（云端测试机要保持联网才能和 GitHub 通信，无法断网运行）。
- 云端模式连接真实服务（需要 API Key）。
- App 内下载模型（推荐模型都在 1.3 GB 以上，放进每次测试会大幅拉长时长）。

9　验收问题与证据

1. SwiftUI 工程是否真实存在?

状态：已完成并验证

App 由 SwiftUI 编写，App 层 20 个源文件，核心库 26 个源文件，合计约 9900 行 Swift，另有约 1800 行测试代码。工程由 XcodeGen 的 project.yml 描述，每次构建自动生成 MoonlitTavern.xcodeproj 后编译。

证据：仓库目录 MoonlitTavern/、Packages/MoonlitCore/、project.yml；MoonlitTavern-XcodeProject.zip 内含 MoonlitTavern.xcodeproj/project.pbxproj。

2. 是否通过真实的 iOS 编译?

状态：已完成并验证

在 GitHub 托管的 macOS 机器上用 xcodebuild 编译 Release、iphoneos、arm64。Xcode 27.1（iOS 27.1 SDK）与 Xcode 26.6（iOS 26.5 SDK）两个版本都编译成功。

证据：Actions 运行 Build #14（编号 40788450491）；build-logs.zip 中的 xcodebuild.log 以 ** BUILD SUCCEEDED ** 结束，environment.log 记录 Xcode 与 SDK 版本。

3. 是否产生了 IPA 或其他可供签名的构建产物?

状态：已完成并验证

产出未签名 IPA，结构检查全部通过：真机平台、arm64、内嵌 llama.framework、未签名、无描述文件。能否安装取决于签名，这一步没有测试。

证据：Releases build-14 中的 MoonlitTavern-unsigned.ipa 及其 .sha256；build-logs.zip 中的 verify-ipa.log。

4. 是否可以导入角色卡?

状态：已完成并验证

支持 PNG（读取 chara 与 ccv3 文本块）和 JSON，兼容 Character Card V1、V2、V3 以及 TavernAI 的字段别名；角色卡内嵌的世界书一起导入；导出时未知字段原样保留。解析与导出由单元测试验证；App 里的导入入口（系统文件选择器）没有纳入 UI 自动化测试。

证据：MoonlitCore/CharacterCards/CharacterCardCodec.swift、PNGChunks.swift；CharacterCardTests（9 项）与 Tests/MoonlitCoreTests/Fixtures/ 样例文件。

5. 聊天记录能否在重启后保留?

状态：已完成并验证（模拟器）

每个存档保存为独立 JSON 文件，原子写入。模拟器测试中先完成一轮对话，再退出并重新启动 App：用户消息与助手消息数量和重启前一致，最后一条回复的文本完全相同；随后又成功生成了一条新回复。

证据：MoonlitCore/Persistence/TavernStore.swift、PersistenceTests；模拟器测试日志 uitest-steps.txt 与截图「10-重启后」「11-重启后继续对话」（仓库 ci-logs/simulator-uitest 分支）。

6. 是否真正调用本地模型?

状态：已完成并验证

推理通过 llama.cpp 的 C 接口完成。IPA 主程序引用了 48 个 llama.cpp 接口；引擎测试和模拟器测试都加载真实 GGUF 文件生成回复，日志里有 Metal 初始化信息、提示词 token 数、实际计算的 token 数和速度。App 里没有预设回复，示例角色的开场白属于角色卡内容，界面上标有「示例」。

证据：MoonlitTavern/Inference/LlamaEngine.swift；verify-ipa.log；docs/evidence/engine-*.log；模拟器截图。

7. 断网后能否生成 AI 回复?

状态：已实现但未验证

本地模式的生成只读取本机模型文件。整个 App 里会联网的代码只在两个文件中：模型下载（用户点击时）和云端引擎（云端模式时）；本地模式选择的是 llama.cpp 引擎，不会调用它们。云端测试机必须保持联网才能和 GitHub 通信，没法在断网条件下实测。真机测试清单第 5 项用飞行模式验证。

证据：App/AppState+Generation.swift 中 activeEngine() 本地模式返回 llama 引擎；网络调用只出现在 Inference/ModelLibrary.swift 与 Providers/OpenAICompatibleEngine.swift。

8. 是否存在任何强制云端依赖?

状态：已完成并验证（不存在）

默认本地模式，不需要账号、服务器或任何在线验证，也没有统计上报。llama.cpp 以框架形式内嵌在 IPA 中。模拟器测试全程使用本地模式。

证据：同上；verify-ipa.log 中的动态库依赖列表只有系统框架和内嵌的 llama.framework。

9. 是否完成 8K 上下文测试?

状态：已完成并验证（macOS 虚拟机）；真机受环境限制

引擎测试以 8192 上下文加载 Qwen3-0.6B，7686 token 的提示词全部读入并正常生成；首发主力 Qwen3.5-4B 也以 8192 上下文完成加载和首轮生成。iPad 上的 8K 测试需要真机，App 内「真机性能测试」的长上下文测试可以完成。

证据：docs/evidence/engine-qwen3-0.6b-ctx8192.log（「长上下文：8192 上下文跑通」）、docs/evidence/engine-qwen35-4b-partial.log。

10. 是否完成真实 iPad 设备测试?

状态：受环境限制

没有可用的 iPad 真机，也没有能连接设备的 Mac。替代验证是 iPad 模拟器端到端测试和 macOS 真实模型引擎测试。真机测试按第 10 章清单进行。

证据：本报告 8.3、8.4 节；第 10 章。

10　真机测试清单

拿到 iPad 后按顺序完成。每项记下结果；遇到失败，把「设置 › 诊断日志」里的内容复制出来。

#	操作	预期结果
1	用全能签签名并安装 IPA	主屏出现「月下酒馆」图标，能正常打开
2	首次启动	出现示例角色艾琳、莱恩和两个示例存档，都带「示例」标记
3	把 Qwen3.5-4B 放进「文件 › 我的 iPad › 月下酒馆 › Models」	模型管理页列出该模型，显示估算内存
4	加载模型（上下文 8192）	加载成功，显示「系统允许本应用再使用约 X MB」。若提示内存不足，记下提示和自动降到的上下文
5	打开飞行模式，在「深夜来客」里发一句话	流式出字，底部显示首 token 时间和速度
6	生成中点停止；再点重新生成；左右切换版本	立即停止；新版本出现；可以来回切换
7	「设置 › 真机性能测试」，依次运行标准测试和长上下文测试	得到首 token、读取与生成速度、内存峰值；复制 Markdown 结果保存
8	导入一张 SillyTavern 的 PNG 角色卡	名称、设定、开场白、头像正确
9	从多任务界面上滑关闭 App，再打开	聊天记录与设置都在
10	进入群聊存档，点名一个角色	被点名的角色发言，不替别人说话
11	连续聊 30 轮以上，或在记忆面板点「立即整理旧消息」	记忆面板出现摘要、事件、关系
12	生成中切到后台，几秒后回来	生成已停止，App 没有闪退
13	「设置 › 备份与恢复」导出完整备份，再从备份恢复	数据完整恢复
14	竖屏、分屏、外接键盘 ⌘ Return 发送	布局正常，快捷键可用

11　已知问题

问题	影响	处理
没有真机测试	速度、内存、发热都是未知数	按第 10 章测试，把性能测试结果反馈回来再调参数
全能签安装未验证	证书或描述文件不符会装不上或闪退	见《安装与使用指南》第 3 章的排查表
默认不带 increased-memory-limit	8 GB 机型可用内存以系统默认为准	描述文件带有该能力时，可在工程里加上权限重新构建
断网推理未实测	代码上本地推理不联网，但没在断网条件下跑过	真机测试清单第 5 项用飞行模式验证
摘要后下一次回复需要重读提示词	记忆内容变化导致缓存失效，那一轮首 token 变慢	后续把记忆放到提示词更靠后的位置
混合架构只保存一个状态快照	回退到更早的位置时需要重读	一般操作（重新生成、停止后再发）不受影响
小模型的摘要质量有限	可能遗漏或编造细节	摘要可以手动编辑；主力模型建议用 4B
云端模式未连接真实服务测试	个别服务商的兼容细节可能有差异	出错信息会显示服务商返回的原文
App 内下载未纳入自动化测试	下载流程只经过代码检查	也可以用 Safari 下载后导入，或直接放进 Models 文件夹
hf-mirror 是第三方镜像	可能限速或不可用	换官方地址，或用其他设备下载后放进 Models 文件夹
模型自带模板回退	少数不常见模板的模型可能格式错乱	在推理设置里手动选择模板
私有仓库的 Actions 时长	macOS 构建按 10 倍计入免费额度	引擎测试和模拟器测试已改为手动触发

12　后续开发路线

第一阶段：真机校准

- 根据真机性能测试结果调整默认上下文、批大小和 KV 缓存类型。
- 修正真机上发现的界面与交互问题。

第二阶段：体验

- 记忆注入位置后移，减少摘要后的缓存失效。
- 多个状态快照，支持任意位置的快速回退。
- 回复语音朗读（系统语音合成）。
- 角色卡与世界书的批量管理。

第三阶段：扩展

- 7B 级模型的实验支持（需要真机内存数据确认可行）。
- 可选 iCloud 同步聊天数据。
- 更多云端服务商的预设。

13　参考资料

- llama.cpp b11960 发布页：https://github.com/ggml-org/llama.cpp/releases/tag/b11960
- Qwen3.5-4B GGUF（unsloth）：https://huggingface.co/unsloth/Qwen3.5-4B-GGUF
- Qwen3.5-2B GGUF（unsloth）：https://huggingface.co/unsloth/Qwen3.5-2B-GGUF
- Qwen3-4B-Instruct-2507 GGUF（lmstudio-community）：https://huggingface.co/lmstudio-community/Qwen3-4B-Instruct-2507-GGUF
- Qwen3-4B-Instruct-2507 模型页（许可）：https://huggingface.co/Qwen/Qwen3-4B-Instruct-2507
- Apple：increased-memory-limit 权限：https://developer.apple.com/documentation/bundleresources/entitlements/com.apple.developer.kernel.increased-memory-limit
- Apple：os_proc_available_memory：https://developer.apple.com/documentation/os/os_proc_available_memory
- Apple 开发者论坛：iPhone app memory limit seems capped to 6GB：https://developer.apple.com/forums/thread/834805
- MLX：模拟器不受支持的讨论（issue 2605）：https://github.com/ml-explore/mlx/issues/2605
- Hugging Face：WWDC 24 Running Mistral 7B with Core ML：https://huggingface.co/blog/mistral-coreml