MOONLIT TAVERN

月下酒馆

安装与使用指南

版本 0.1.0 · 构建 #14

适用设备：iPad（M 系列芯片）· iPadOS 27

2026 年 10 月

本文档由@呜呜鼬创建，未经许可不得外传。

目录

1 先看这一页 3

2 获取安装包 3

3 用全能签安装 4

3.1 需要准备什么 4

3.2 签名与安装 4

3.3 关于权限与内存 4

3.4 装不上怎么办 4

4 准备模型 5

4.1 选哪个模型 5

4.2 三种放入方式 5

4.3 选择与加载 6

5 开始角色扮演 6

5.1 界面 6

5.2 对话操作 6

5.3 角色卡 6

5.4 世界书 7

5.5 长期记忆 7

5.6 群聊 7

6 设置与数据 7

6.1 推理参数 7

6.2 云端模式（可选） 8

6.3 备份与恢复 8

6.4 真机性能测试 8

7 常见问题 8

1　先看这一页

月下酒馆是一款在 iPad 上离线运行大语言模型的角色扮演应用。模型的计算全部在 iPad 的 M4 芯片上完成，聊天内容不经过任何服务器。

从零开始到第一次对话，一共四步：

1. 下载安装包 MoonlitTavern-unsigned.ipa（约 5 MB）。
2. 用全能签配合你自己的证书签名、安装。
3. 下载一个 GGUF 模型（推荐 Qwen3.5-4B，2.74 GB），放进 App。
4. 打开示例存档「深夜来客」，发一句话。

> **提示**　安装包里不带模型。模型文件有几个 GB，单独下载、单独存放，换模型不用重装 App。

项目	内容
App 名称	月下酒馆（Moonlit Tavern）
Bundle ID	com.wuwuyou.moonlittavern
版本	0.1.0（构建 #14）
最低系统	iPadOS 17.0；面向 iPadOS 27 编译（iOS 27.1 SDK）
设备	仅 iPad；推荐 M 系列芯片、8 GB 及以上内存
推理引擎	llama.cpp（b11960），Metal GPU 加速

2　获取安装包

安装包由 GitHub Actions 在 macOS 机器上自动编译，每次更新代码都会生成一个新版本，发布在仓库的 Releases 页面。

1. 在 iPad 的 Safari 打开 github.com/wwuwubo/moonlit-tavern，登录你的 GitHub 账号（仓库是私有的）。
2. 进入「Releases」，打开最新的「月下酒馆 构建 #N」。
3. 下载 MoonlitTavern-unsigned.ipa，存到「文件」App。

文件	说明
MoonlitTavern-unsigned.ipa	真机（iphoneos）Release 版本，**未签名**，不能直接安装
MoonlitTavern-unsigned.ipa.sha256	安装包的 SHA-256 校验值
MoonlitTavern-XcodeProject.zip	完整源码与工程描述，有 Mac 时可自行编译
build-logs.zip、core-tests.log	编译日志、IPA 结构检查结果、单元测试输出

> **为什么叫 unsigned**　「未签名」的意思是：包里没有任何证书和描述文件，iPadOS 不允许直接安装。必须先用签名工具配上你自己的证书。

3　用全能签安装

3.1　需要准备什么

- 一张可用的签名证书：.p12 文件和它的密码。
- 与证书配套的描述文件 .mobileprovision。如果是开发证书或 Ad Hoc 证书，描述文件里必须登记了这台 iPad 的 UDID；企业证书不需要 UDID。
- iPad 已开启「开发者模式」（设置 › 隐私与安全性 › 开发者模式）。用开发证书签名的 App，没开开发者模式会打不开。
- 全能签已安装，证书已导入。

3.2　签名与安装

1. 在「文件」里长按 MoonlitTavern-unsigned.ipa，选「共享」，发送到全能签；或者在全能签里通过「导入文件」选择它。
2. 在全能签的文件列表中点开这个 IPA，选择「签名」。
3. 选择你的证书。Bundle ID 建议保持 com.wuwuyou.moonlittavern 不变，其他选项保持默认。
4. 点「立即签名」，完成后在已签名列表里点「安装」。
5. 回到主屏幕，等「月下酒馆」图标安装完成后打开。

> **更新时**　以后每次更新，请用**同一张证书、同一个 Bundle ID** 覆盖安装，聊天记录、角色和模型才会保留。换了 Bundle ID，系统会把它当成另一个 App，数据不互通。

3.3　关于权限与内存

安装包没有申请任何特殊权限（entitlements），普通证书就能签。

苹果提供一个「提高内存上限」的权限（com.apple.developer.kernel.increased-memory-limit），能让 App 在部分机型上使用更多内存。它只有在你的描述文件本身包含这项能力时才可能生效，第三方渠道的证书通常没有。不带这项权限，App 一样能运行：加载模型前会读取系统实际允许的内存，放不下 8K 上下文时自动降到 6K 或 4K，并在界面上提示。

3.4　装不上怎么办

现象	常见原因	处理
安装时提示无法验证或安装失败	描述文件不含这台 iPad 的 UDID	换包含本机 UDID 的描述文件，或用企业证书
图标灰色、点开闪退	证书已过期或被吊销	换有效证书重新签名

现象	常见原因	处理
提示需要开发者模式	开发证书签名但未开启开发者模式	设置 › 隐私与安全性 › 开发者模式，开启后重启
全能签提示签名失败	证书密码错误，或全能签版本过旧	核对 p12 密码，更新全能签

> **提醒**　证书一旦被吊销，App 就打不开了，但数据还在。换证书、用相同 Bundle ID 重新签名安装即可恢复。为保险起见，请定期在「设置 › 备份与恢复」导出一份完整备份。

4　准备模型

4.1　选哪个模型

定位	模型与文件	大小	说明
首选	Qwen3.5-4B Qwen3.5-4B-Q4_K_M.gguf	2.74 GB	中文表达和人设遵循最好；混合注意力架构，8K 上下文额外内存很小
备用	Qwen3-4B-Instruct-2507 Qwen3-4B-Instruct-2507-Q4_K_M.gguf	2.50 GB	标准架构，兼容性最稳；8K 上下文的 KV 缓存约 0.6 GB
轻量	Qwen3.5-2B Qwen3.5-2B-Q4_K_M.gguf	1.28 GB	更快、更省内存；文笔和角色一致性弱于 4B

三个模型都采用 Apache-2.0 许可，可以自由使用。

4.2　三种放入方式

方式一：在 App 里下载

打开「设置 › 模型管理」，在推荐模型下点「从 hf-mirror 下载」或「从 Hugging Face 下载」。国内网络一般选 hf-mirror（第三方镜像，可用性随时可能变化）。下载期间请保持 App 在前台、屏幕常亮。

方式二：Safari 下载后导入

在 Safari 下载 .gguf 文件，存进「文件」。然后在「模型管理」右上角点「导入」，选中它。App 会复制一份到自己的目录，导入完成后原文件可以删掉。

方式三：直接放进 App 的文件夹（最省空间）

打开「文件」App，进入「我的 iPad › 月下酒馆 › Models」，把 .gguf 文件**移动**进去。回到「模型管理」下拉刷新，就能看到它。这样整个过程只占一份空间。

> **说明**　模型文件夹不参与 iCloud 备份，不会占用你的 iCloud 空间。

4.3　选择与加载

在「模型管理」里点一下模型即选中。不需要手动加载：发第一条消息时会自动加载，加载进度显示在左上角。每个模型下方都列出了理论内存估算（权重、KV 缓存、计算缓冲、应用本身），以及系统当前允许 App 使用的内存。

第一次加载时，Metal 需要准备 GPU 着色器，可能要多等几秒到十几秒；之后会快很多。

5　开始角色扮演

5.1　界面

区域	内容
左侧	角色、存档、群聊。顶部显示当前模型和是否离线。右上角「+」新建或导入角色、新建群聊、管理世界书
中间	对话。底部输入框，下方一行显示首 token 延迟、读取和生成速度、上下文用量、内存
右侧	面板，分五页：角色、世界书、记忆、参数、上下文。工具栏右侧按钮可以收起

首次打开时有两个标着「示例」的角色（艾琳、莱恩）、一本示例世界书和两个示例存档，用来演示各项功能。不需要时可以直接删除。

5.2　对话操作

操作	方法
发送	点右侧按钮；外接键盘按 Command + Return
停止生成	生成时按钮变成红色方块，点它；外接键盘按 Command + 句号
让角色继续	输入框留空，点按钮
重新生成	最后一条回复下方「重新生成」；旧版本保留，用 ‹ 1/2 › 切换
编辑、复制、删除	长按消息
分支剧情	长按消息 › 从这里分出新存档
不让模型看到某条	长按消息 › 不让模型看到这条（仍保留在记录里）
新存档	左侧角色下方「新存档」；同一角色可以有多个存档

5.3　角色卡

- **导入**：左侧「+」› 导入角色卡，支持 PNG 和 JSON，兼容 Character Card V1、V2、V3。角色卡里自带的世界书会一起导入。

- **编辑**：长按角色 › 编辑角色，或在右侧面板「角色」页点「编辑角色」。字段与 SillyTavern 一致，另有「背景」「说话风格」两项。
- **导出**：编辑页底部可导出 PNG（同时写入 V2 和 V3 数据，SillyTavern 可直接读取）或 JSON。

5.4 世界书

世界书按关键词把设定注入提示词。每个存档可以勾选使用哪几本（右侧面板「世界书」页），角色自带的世界书始终生效。

- **常驻**条目每次都注入；普通条目在最近几条消息里出现关键词时注入。
- **次要关键词**可以组合：任意一个、全部、一个都没有、没有全部。
- **剧情状态条件**：在右侧面板维护「月相=满月」这类状态，条目可以设成只在满足条件时生效。
- **粘滞、冷却、延迟**：激活后持续几轮、失效后冷却几轮、对话满多少条后才允许激活。
- **预算**：世界书内容有 token 上限，超出时按优先级从低到高舍弃。右侧面板会列出上一轮注入了哪些条目、哪些因预算没放进去。
- 可以导入 SillyTavern 的世界书 JSON，也可以导出给 SillyTavern 使用。

5.5 长期记忆

对话变长后，最早的消息会移出模型的上下文。App 会把移出的消息交给模型整理成「摘要、关键事件、角色关系、剧情状态」，存为长期记忆；之后每轮按关键词挑出相关的几条放回提示词。

- 右侧面板「记忆」页可以查看、编辑、删除每条记忆，或设为「常驻」。
- 「立即整理旧消息」会马上整理一次（最近 6 条保留原文）。
- 整理也由本地模型完成，同样离线。

5.6 群聊

左侧「+」› 新建群聊，选两个以上角色。发言顺序有四种：自然（被点名的角色优先）、轮流、按积极度随机、手动。输入框上方的头像按钮可以直接指定下一位发言者。

每次只让一个角色说话，提示词里标明「现在轮到谁」，并设置停止词，防止模型替其他角色或替你说话。

6 设置与数据

6.1 推理参数

参数	建议
上下文长度	8192 起步。加载失败或后台常被系统关掉时，改 6144 或 4096
KV 缓存精度	Q8_0（需开启 Flash Attention），比 F16 省一半

参数	建议
回复长度	简短 160 / 适中 320 / 详细 640 token，也可自定义
温度	0.7–0.9。越高越有创意，也越容易跑题
思考模式	保持关闭。角色扮演不需要模型先「思考」

6.2 云端模式（可选）

在「设置 › 云端 › OpenAI 兼容 API」里填写兼容 OpenAI 接口的服务（例如 OpenRouter），再把设置页顶部的推理方式切到「云端 API」。API Key 只保存在本机钥匙串，不进备份、不进日志。

只有在切换到「云端 API」时才会联网发送对话内容；切回「本地模型」后立即停止。角色、世界书、聊天记录无论哪种模式都只存在 iPad 上。

6.3 备份与恢复

「设置 › 备份与恢复」可以导出一个 JSON 文件，包含角色、头像、存档、世界书、长期记忆和设置（不含模型文件和 API Key）。恢复时按条目覆盖，备份里没有的现有数据会保留。

6.4 真机性能测试

「设置 › 真机性能测试」有两个按钮：

- **测速**：约 600 token 的提示词加 128 token 生成，测首 token 延迟、读取速度、生成速度和内存。
- **长上下文测试**：把提示词填到接近当前上下文长度，验证 8K 能否在这台 iPad 上跑通。

结果保存在本机，右上角可以复制成表格。这些数字都来自这台 iPad 的实际运行。

7 常见问题

问题	处理
提示内存不足 / 加载失败	把上下文降到 4096；换更小的量化（Q4_K_S、IQ4_XS）；或换 Qwen3.5-2B。关掉其他占内存的 App 后重试
切到后台再回来，模型需要重新加载	iPadOS 会回收后台占用大量内存的 App，属于系统行为。生成中切后台会自动停止，已生成的内容会保留
回复变成英文	在开场白和你的消息里坚持用中文；也可以在角色的系统提示词里写明「用中文回复」
回复里出现奇怪的符号或自言自语	在「推理参数」把模板改回「自动识别」，确认思考模式已关闭
角色替我说话	一般是模型能力问题。可以在角色的「历史后指令」里强调「不要替用户说话」，或降低温度

问题	处理
iPad 发热、越聊越慢	长时间推理会让芯片降频，属正常现象。界面底部会显示温度状态
下载模型很慢或失败	换「从 hf-mirror 下载」；或用电脑、其他设备下载后通过「文件」拷进 Models 文件夹